


엔트로픽 보고서: 힘과 통제의 역설

AI 혁명 시대, 엑셀과 브레이크를 동시에 밟는
가장 이질적인 프론티어의 해부



파괴적 혁신 (Disruptive Power)

- 1조 달러에 육박하는 기업 가치 도달



- 엔지니어링 코드 작성의 100% 자동화 달성



- 세계 최고 수준의 코딩 AI 모델 전격 출시



실존적 경고 (Existential Restraint)

- 인류 문명 붕괴 확률 10~25% 경고



- 자발적인 기술 통제 및 초강력 규제 촉구




- 통제 불능을 막기 위한 헌법적 방어선 구축


세계에서 **가장 강력한 무기**를 만들면서,
동시에 그 무기의 **위험성**을 **가장 강하게 경고**하는 딜레마.



기원과 결별: 신뢰와 비전의 분기점



헌법적 엔진: 가치의 내재화 (Constitutional Engine)



1단계: 보편적 가치 수집

UN 세계인권선언 및 보편적 종교 윤리.
특정 세계관을 초월하여 인류가
고민해 온 핵심 가치 추출.

2단계: 헌법적 필터링

모델에 윤리를 직접 내재화(Bake-in).
의도적 기만 및 환각 현상을 차단하고
무해성(Harmlessness) 확보.

3단계: AI 특성 발현

유해 정보를 원천 차단하는 클로드(Claude)만의
독특하고 안전한 성격 아키텍처 완성.

정밀한 성격 조율 (Tuning the Persona)

차갑고 기계적인 연산

전문적인 따뜻함
(Professional Warmth)

지나치게 친밀한 간섭



초기 모델의 지나친 간섭 성향을 폐기하고,
접근하기 쉬우면서도 적절한 거리를 유지하는
정밀한 다이얼 조율의 결과물.

가치관이 반영된 비즈니스 모델 (Business Matrix)

소비자용 AI (B2C 모델)	엔터프라이즈 AI (B2B 모델)
• 소셜 미디어의 악습 반복 • 도파민 자극 및 체류 시간 극대화 • 무분별한 배포 (YOLO)	• 바이오테크 질병 치료 및 제약 • 에너지 효율화 및 기업 생산성 혁신 • 중독이 아닌 '도구'로서의 베틱

“

자신의 가치관과 근본적으로 충돌하는 비즈니스 모델을 선택하면,
결국 자신의 가치를 배신하거나 시장에서 도태될 수밖에 없다.

”

생산성의 퀀텀 점프: 하얀 칼라의 소멸

- **80x 폭발적 성장:** 2024년 1분기 기준, 연환산 80배의 성장률 달성.

- **100% 자동화:** 클로드 코드를 통한 핵심 엔지니어 코딩 업무 완벽 대체.

- **50% 대체 전망:** 1~5년 내 초급 사무직의 절반이 소멸할 수 있다는 충격적 전망.


단순히 10배 생산적인 구간을 지나, AI가 모든 것을 대체하는 100% 수렴점에 도달 중이다.



일자리의 재편: 인간 중심주의로의 회귀

1단계: 논리/연산의 완벽한 자동화

A



의사의 진단, 법률 분석, 코딩 등
논리적 영역은 AI가 압도.

2단계: 경제적 파이의 팽창

B



전례 없는 생산성 폭발로 인한
거시 경제 규모의 극적 확대.

3단계: 대인관계 및 물리적 노동의 부상


C



공감, 돌봄, 그리고 물리적 제조 등
인간 관계(Human-to-Human)
중심 직업으로의 축 이동.



AI가 질병 진단은 더 정확히 하겠지만, 침대 곁에서 환자의 손을 잡고
위로하는 영역으로 직업의 중심이 이동할 것이다.



사이버 안보와 통제된 배포 (The Superweapon)

슈퍼 무기 '미토스 (Mythos)'

전 세계 주요 운영체제(OS)의 취약점을
단숨에 찾아낸 비밀 모델. 시장은 이를 **총기
면허가 필요한 사이버 슈퍼 무기**로 평가.



유보적 결단: 프로젝트 글래스 윙

프로젝트 운영체제(OS) 사이버 안보와
막대한 상업적 수익과 맹목적 배포를 포기.
방어적 역할을 수행하는 극소수 국가 기관
에게만 접근을 허용하는 엄격한 통제 전략.

국방부와의 갈등과 타협 불가능한 레드라인

애국적 결단 (협력)

독재 국가의 AI 패권 확장을 막기 위해
2억 달러 규모의 펜타곤 계약 참여 및
정보 분석 보조.



Red Line

레드라인 (금지)

대중 감시 및 자율 살상 무기
시스템에 클로드 사용 전면 금지.



클로드는 정보 분석을 보조할 수 있지만, 발사 버튼은
반드시 인간이 눌러야 한다 (Human in the loop).

규제의 패러독스 (The Regulatory Reversal)



실리콘밸리의 극단성

초기에는 규제가 **혁신을 죽인다**며 반대하다가,
통제할 수 없는 위협을 마주하자
돌연 정부의 압수와 완전 국유화를 외치는 **요요 현상**.

엔트로픽의 중도적 해법

패닉을 멈추고 지수함수를 인정하라.
가장 강력한 모델에 대한 의무적인
출시 전 보안 감사 제도화.

오픈하이머의 함정: 다중 견제 시스템

단일 영웅 서사의 실패




초인적인 리더 한 명이 세상을 구하는 방식은 실패한다.
거대한 이해관계자들이 거미줄처럼
서로를 감시하는 시스템만이 유일한 보호막.

견제와 균형 (Checks and Balances)



최초의 민간 주도 초권력
핵무기나 인터넷과 달리, 역사상 처음으로
정부가 아닌 사기업이 주도하는 파괴적 기술.



25%의 리스크를 대하는 태도

■ 인류 문명 붕괴 확률: 10~25%

■ 치명적 룰렛

추락 확률이 25%인 비행기가 있다면 당신은 탑승하겠는가? **25%는 절대 무시할 수 없는 너무 높은 수치다.**

■ 극한의 방어 엔지니어링

엔트로픽 절반의 인력은 AI를 개발하고, 나머지 절반은 이 **리스크를 0%에 수렴**시키기 위한 철학적, 기술적 방어에 투입됨.

최고를 희망하고, 최악을 대비하라



헌법적 통제

압도적 생산성

창조자의 무한 책임

우리는 그저 제품을 성장시키려 했을 뿐인데
사회가 망가졌다고 변명하는 것은
기술 기업의 수치다.

거시경제적 고민

AI 촉발 불평등을 완화하기 위해
보편적 기본소득(UBI)과 누진세 등 적극적인 경제
정책 도입까지 지지하는 이례적 행보.

멈출 수 없는 지수곡선 위에서

악의적인 행위자가 초거대 AI를 **무기화하는** 것을 막는 유일한 방법은,
선한 의도와 철저한 통제력을 갖춘 자가 가장 뛰어난 모델을 선점하는 것뿐이다.

엑셀과 브레이크를 동시에 밟아야만 하는 모순.
그것이 엔트로픽이 이 **위험한 프론티어**의 최전선에서 결코 물러서지 않는 이유입니다.

